

# Appunti di Statistica Matematica

## 1 Introduzione

### 1.1 Funzione generatrice dei momenti

Lezione del 18/02, ultima modifica 04/03, Andrea Gadotti

**Definizione 1.** Sia  $X$  una variabile casuale (discreta o assolutamente continua). Se esiste  $t_0 > 0$  tale per cui  $\mathbb{E}(e^{tX}) < +\infty \forall t \in (-t_0, t_0)$ , chiameremo la funzione

$$M_X := \mathbb{E}(e^{tX})$$

funzione generatrice dei Momenti di  $X$ .

#### Esempi

1.  $X \sim b(1, p)$  con  $p \in (0, 1)$ . Si ha:

$$\begin{aligned} M_X(t) &= \mathbb{E}(e^{tX}) = \sum_{x=0}^1 e^{tx} \mathbb{P}(X = x) \\ &= \sum_{x=0}^1 e^{tx} p^x (1-p)^{1-x} = pe^t + (1-p) \end{aligned}$$

2.  $X \sim P(\lambda)$  con  $\lambda > 0$ . Si ha:

$$M_X(t) = \mathbb{E}(e^{tX}) = \sum_{x=0}^{+\infty} e^{tx} \frac{e^{-\lambda} \lambda^x}{x!} = e^{\lambda(e^t - 1)}$$

3.  $X \sim G(\alpha, \beta)$ , ovvero

$$f_X(x; \alpha, \beta) := \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-\frac{1}{\beta}x}$$

con  $\alpha > 0$ ,  $\beta > 0$ ,  $x > 0$  e

$$\Gamma(\alpha) := \int_0^{+\infty} x^{\alpha-1} e^{-x} dx$$

(nota:  $\alpha \in \mathbb{N} \implies \Gamma(\alpha) = (\alpha - 1)!$ )

Abbiamo che:

$$M_X(t) = \mathbb{E}(e^{tX}) = \int_0^{+\infty} e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-\frac{1}{\beta}x} dx$$

$$= \dots [\text{sostituzione } \sigma := x(\frac{1}{\beta} - t)] \dots$$

$$= \frac{1}{(1 - \beta t)^\alpha}$$

$$\text{con } t < \frac{1}{\beta}$$

## Momenti di una variabile casuale

**Definizione 2.** Se una variabile casuale ammette FGM derivabile infinite volte in un intorno di  $t = 0$  e se tutti i suoi momenti sono finiti, allora definiamo il momento di ordine  $s$  non centrato:

$$\mu'_s := \mathbb{E}(X^s) = \frac{d^s}{dt^s} M_X(t) |_{t=0}$$

Il momento di ordine  $s$  centrato in  $a \in \mathbb{R}$  è:

$$\mu_s(a) := \mathbb{E}((X - a)^s)$$

Ovvero  $\mu'_s = \mu_s(0)$ . E' chiaro che  $\mu'_1 = \mathbb{E}(X)$ . Chiameremo infine momento di ordine  $s$  centrato (senza specificare altro, intenderemo centrato in  $\mu'_1$ ):

$$\mu_s := \mathbb{E}((X - \mu'_1)^s)$$

**Teorema 1.** Vale la seguente relazione tra momenti centrati e non:

$$\mathbb{E}((X - \mu'_1)^s) = \sum_{m=0}^s (-1)^m \binom{s}{m} \mu'_{s-m} (\mu'_1)^m$$

$$\text{Osserviamo che } \mu_2 = \mathbb{E}((X - \mu'_1)^2) = \text{Var}(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2 = \mu'_2 - (\mu'_1)^2$$

**Teorema 2.** Date due (o più) v.c.  $X$  e  $Y$  aventi f densità / f massa  $f_X$  e  $f_Y$  e fgm  $M_X(t)$  e  $M_Y(t)$  rispettivamente e assunte  $X$  e  $Y$  essere indipendenti, allora si ha

$$M_{X+Y} = M_X(t) M_Y(t)$$

**Teorema 3.** Siano  $X$  e  $Y$  v.c. con funzioni di ripartizione  $F_X(x)$  e  $F_Y(y)$  rispettivamente. Siano  $M_X(t)$  e  $M_Y(t)$  le fgm di  $X$  e  $Y$ . Se  $M_X(t) = M_Y(t)$  per ogni  $t$  in un intorno dell'origine, allora

$$X \stackrel{d}{=} Y$$

**Osservazione 1.** Il teorema appena visto ci dice sostanzialmente che, se esiste, la fgm caratterizza la distribuzione della corrispondente v.c.

**Esempio** Siano  $(X_1, \dots, X_n)$  risultati della replicazione di un esponenziale casuale dicotomico ( $X_i \sim b(1, p)$ ). Vogliamo trovare la distribuzione di  $S_n := \sum_{i=1}^n X_i$ . Calcoliamo quindi la sua fgm:

$$M_{S_n}(t) = \mathbb{E}(e^{tS_n}) = \mathbb{E}(e^{t \sum_{i=1}^n X_i})$$

$$\stackrel{TEO1}{=} \prod_{i=1}^n \mathbb{E}(e^{tX_i}) = \prod_{i=1}^n M_{X_i}(t) = \prod_{i=1}^n (pe^t + (1-p)) = (pe^t + (1-p))^n$$

ovvero  $S_n$  è distribuita come  $b(n, p)$  per il Teorema 2.

**esercizio** Ripetere il calcolo precedente supponendo  $X_i \sim P(\lambda), \forall i$ .

## 1.2 Famiglia Esponenziale a $k$ parametri

Una famiglia di  $f$  densità /  $f$  massa è detta essere una Famiglia Esponenziale a  $k$  parametri  $\theta_1, \dots, \theta_k$  se la corrispondente  $f$  densità /  $f$  massa (che è indicizzata da  $\theta_1, \dots, \theta_k$ ) può essere scritta come

$$f_X(x; \theta) = C^*(x) D^*(\theta) \left\{ \sum_{m=1}^k A_m(\theta) B_m(x) \right\}$$

dove  $C^*(x)$  è una funzione della sola  $x$ ,  $D^*(\theta)$  è una funzione del solo  $\theta$ ,  $A_m(\theta)$  è una funzione del solo  $\theta$  e  $B_m(x)$  è una funzione della sola  $x$ . **Esempi**

1.  $X \sim G(\alpha, \beta) \implies f_X(x; \alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-\frac{1}{\beta}x} \mathbb{1}_{\mathbb{R}^+}(x)$ ,  $\alpha > 0$ ,  $\beta > 0$   $\mathbb{1}_{\mathbb{R}^+}$  è detto supporto della distribuzione. Quindi possiamo riscrivere  $f_X(x; \alpha, \beta)$  come

$$f_X(x; \alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} \mathbb{1}_{\mathbb{R}^+}(x) \exp((\alpha-1)\ln(x) - \frac{1}{\beta}x)$$

e quindi ponendo  $D^*(\alpha, \beta) := \frac{1}{\Gamma(\alpha)\beta^\alpha}$ ,  $C^*(x) := \mathbb{1}_{\mathbb{R}^+}(x)$ ,  $A_1(\alpha, \beta) := (\alpha-1)$ ,  $B_1(x) := \ln(x)$ ,  $A_2(\alpha, \beta) := -\frac{1}{\beta}$  e  $B_2(x) := x$ , otteniamo  $G(\alpha, \beta)$  come famiglia esponenziale con  $k = 2$ .

2.  $X \sim b(n, p) \implies f_X(x; n, p) = \binom{n}{x} p^x (1-p)^{n-x} \mathbb{1}_{\{0,1,\dots,n\}}(x)$  con  $n \in \mathbb{N}$  noto. Quindi possiamo riscrivere  $f_X(x; n, p)$  come

$$f_X(x; n, p) = \binom{n}{x} \mathbb{1}_{\{0,1,\dots,n\}}(x) (1-p)^n \exp(\ln(\frac{p}{1-p})x)$$

con  $\frac{p}{1-p}$  detto odd ratio o parametra naturale della famiglia esponenziale.

Quindi ponendo  $D^*(p) := (1-p)^n$ ,  $C^*(x) := \binom{n}{x} \mathbb{1}_{\{0,1,\dots,n\}}(x)$ ,  $A_1(p) := \ln(\frac{p}{1-p})$ ,  $B_1(x) := x$ , otteniamo  $b(n, p)$  come famiglia esponenziale con  $k = 1$ .

**Osservazione 2.** Le famiglie di esponenziali hanno interessanti proprietà matematiche (proprietà di regolarità).

Dal punto di vista statistico, ciò si traduce in un'interessante conseguenza: tutta l'informazione contenuta nei dati a disposizione  $(X_1, \dots, X_n)$  relativa alla funzione  $f_X(x; \theta)$  può essere sintetizzata attraverso  $k$  quantità (funzioni di  $(X_1, \dots, X_n)$ ) che potranno essere impiegate per costruire procedure inferenziali (stima, test per la verifica di ipotesi) riguardanti il parametro  $\theta$ .

Ovvero, l'appartenenza ad una famiglia esponenziale permette una riduzione dei dati  $(X_1, \dots, X_n)$  via  $B_m$ .

## 1.3 Trasformazioni di variabili casuali

Lezione del 01/03, ultima modifica 03/03, Michele Nardin

### Discrete

**Teorema 4.** Sia  $X$  una vc con funzione di massa  $f_X(x) = P(X = x)$ , e sia  $A_X$  il suo supporto. Sia  $W=h(X)$  una nuova vc. Allora

$$P(W = w) = \sum_{\{x \in A_X : h(x)=w\}} P(X = x)$$

## Esempi

1. Sia  $X \sim b(n, p)$  con relativa funzione di massa  $f_X(x, p) = \binom{n}{p} p^x (1-p)^{n-x} \mathbb{1}_{0,1,\dots,n}(x)$ ,  $n$  noto e  $p \in (0, 1)$ .

Considero quindi  $W = n - X$ . Come si distribuisce  $W$ ?

$$P(W = w) = P(X = n - w) = \binom{n}{n-w} p^{n-w} (1-p)^w \mathbb{1}_{0,1,\dots,n}(w)$$

2. Sia  $X$  una vc tale che  $f_X(x) = P(X = x) = \left(\frac{1}{2}\right)^x \mathbb{1}_{\mathbb{N}}(x)$ ,  $W = X^3$ .

$$P(W = w) = P(X^3 = w) = P(X = \sqrt[3]{w}) = \left(\frac{1}{2}\right)^{\sqrt[3]{w}} \mathbb{1}_{1,8,27,\dots}(w)$$

## Assolutamente continue

**Teorema 5.** Sia  $X$  una variabile casuale (ass continua) con funzione di densità  $f_X(x)$  e sia  $W = h(X)$ , ove  $h$  è una funzione monotona. Supponiamo inoltre che  $f_X(x)$  sia continua sul supporto di  $X$  e che  $h^{-1}(w)$  abbia derivata continua sul supporto di  $W$ . Allora

$$f_W(w) = f_X(h^{-1}(w)) \left| \frac{d}{dw} h^{-1}(w) \right| \mathbb{1}_{A_W}(w)$$

**Esempio** (Standardizzazione di una vc normale) Sia  $X \sim N(m, s^2)$ . Considero  $W = h(X) = \frac{X-m}{s}$ . Allora, dato che  $h^{-1}(w) = sw + m$ , che ha derivata continua su tutto  $\mathbb{R}$ ,

$$f_W(w) = f_X(sw + m) |s| = \frac{e^{-\frac{w^2}{2}}}{\sqrt{2\pi}}$$

**Teorema 6.** Se  $W = h(X)$  ove  $h$  è monotona a tratti (un numero finito  $k$ ) e valgono le condizioni del teorema precedente (su ogni tratto), allora

$$f_W(w) = \sum_{n=1}^k f_X(h_n^{-1}(w)) \left| \frac{d}{dw} h_n^{-1}(w) \right| \mathbb{1}_{A_W}(w)$$

**Esempio** (Chi-quadro): Sia  $X \sim N(0, 1)$  e  $W = h(X) = X^2$ .  $h$  è monotona sui tratti  $A_0 = 0$ ,  $A_1 = (-\infty, 0)$ ,  $A_2 = (0, +\infty)$ . Trovo inoltre  $h_1^{-1}(w) = -\sqrt{w} \in A_1 \forall w \geq 0$ , mentre  $h_2^{-1}(w) = \sqrt{w} \in A_2 \forall w \geq 0$ .  $\frac{d}{dw} h_1^{-1}(w) = -\frac{1}{2\sqrt{w}}$ ,  $\frac{d}{dw} h_2^{-1}(w) = \frac{1}{2\sqrt{w}}$  sono entrambe continue su  $\mathbb{R}_+$ .

$$\begin{aligned} f_W(w) &= \frac{1}{\sqrt{2\pi}} e^{-\frac{(-\sqrt{w})^2}{2}} \left| \frac{1}{2\sqrt{w}} \right| + \frac{1}{\sqrt{2\pi}} e^{-\frac{(\sqrt{w})^2}{2}} \left| \frac{1}{2\sqrt{w}} \right| \\ &= \frac{1}{\sqrt{2\pi w}} e^{-\frac{w}{2}} \mathbb{1}_{\mathbb{R}_+}(w) = \frac{1}{2^{1/2} \Gamma(1/2)} w^{\frac{1}{2}-1} e^{-\frac{w}{2}} \end{aligned}$$

Si riconosce che  $W \sim \mathcal{G}(\alpha = 1/2, \beta = 2)$  e si chiama Chi quadrato con  $\nu = 1$  gradi di libertà. In generale, una vc Chi Quadro con  $\nu = n$  gradi di libertà è  $W = \sum_{i=1}^n X_i^2$ , ove  $X_1, X_2, \dots, X_n$  sono vc iid  $N(0,1)$ . Per il teorema sulla FGM di una somma di vc iid si trova immediatamente che  $W \sim \mathcal{G}(\alpha = n \cdot 1/2, \beta = 2)$ .

## 1.4 Convergenze

### Convergenza in probabilità

**Definizione 3.** Sia  $\{X_n\}_{n \in \mathbb{N}}$  una successione di variabili casuali e sia  $X$  un'altra variabile casuale, tutte definite sullo stesso spazio campionario. Diciamo che  $X_n$  converge in probabilità a  $X$  (scriviamo  $X_n \xrightarrow{p} X$ ) se  $\forall \varepsilon > 0$

$$\lim_{n \rightarrow \infty} P(|X_n - X| \leq \varepsilon) = 0$$

**Osservazione 3.** Se  $X_n \xrightarrow{p} X$  diciamo che la massa della differenza  $|X_n - X|$  converge a 0. Inoltre, quando scriviamo  $X_n \xrightarrow{p} X$ , stiamo sottintendendo tutta la parte iniziale della definizione precedente, cioè il sia  $\{X_n\}_{n \in \mathbb{N}}$  una successione di variabili casuali....

**Teorema 7.** Alcuni risultati utili:

1. Supponiamo che  $X_n \xrightarrow{p} X$  e  $Y_n \xrightarrow{p} Y$ . Allora  $X_n + Y_n \xrightarrow{p} X + Y$
2. Supponiamo che  $X_n \xrightarrow{p} X$  e sia  $a$  una costante. Allora  $aX_n \xrightarrow{p} aX$
3. Supponiamo che  $X_n \xrightarrow{p} a$  costante, e sia  $g$  una funzione reale continua in  $a$ . Allora  $g(X_n) \xrightarrow{p} g(a)$
4. (Corollario di 3.) Se  $X_n \xrightarrow{p} a$ , allora  $X_n^2 \xrightarrow{p} a^2$ ,  $\frac{1}{X_n} \xrightarrow{p} \frac{1}{a}$  (se  $a \neq 0$ ),  $\sqrt{X_n} \xrightarrow{p} a$  ( $a \geq 0$ ).
5.  $X_n \xrightarrow{p} X$  e  $Y_n \xrightarrow{p} Y$  allora  $X_n Y_n \xrightarrow{p} XY$

### Convergenza in distribuzione

**Definizione 4.** Sia  $\{X_n\}_{n \in \mathbb{N}}$  una successione di variabili casuali e sia  $X$  un'altra variabile casuale, tutte definite sullo stesso spazio campionario.

Siano  $F_{X_n}$  e  $F_X$  le relative funzioni di ripartizione (di distribuzione, sinonimo). Sia  $C(F_X)$  l'insieme dei punti ove  $F_X$  è continua. Diciamo che  $X_n$  converge in distribuzione (o in legge) a  $X$  (scriviamo  $X_n \xrightarrow{d} X$ ) se

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x) \forall x \in C(F_X)$$

**Teorema 8.** Se  $X_n \xrightarrow{p} X$  allora  $X_n \xrightarrow{d} X$ .

**Osservazione 4.** Il contrario in generale non vale, tranne nel caso in cui  $X$  è una vc degenera (cioè costante).

**Teorema 9.** Supponiamo che  $X_n \xrightarrow{d} X$  e sia  $g$  una funzione continua sul supporto di  $X$ . Allora  $g(X_n) \xrightarrow{d} g(X)$

**Teorema 10** (Slutsky). Supponiamo che  $X_n \xrightarrow{d} X$ ,  $A_n \xrightarrow{p} a$  costante e  $B_n \xrightarrow{p} b$  costante. Allora  $A_n + B_n X_n \xrightarrow{d} a + bX$

## 1.5 Teoria asintotica

Lezione del 04/03, ultima modifica 05/03, Michele Nardin

**Teorema 11.** ( $\Delta$ -method) Sia  $\{X_n\}_{n \in \mathbb{N}}$  una successione di vc tale che

$\sqrt{n}(X_n - \vartheta) \xrightarrow{d} N(0, \sigma^2)$ . Supponiamo che una funzione  $g(X)$  sia derivabile in  $\vartheta$  e che  $g'(\vartheta) \neq 0$ . Allora

$$\sqrt{n}(g(X_n) - g(\vartheta)) \xrightarrow{d} N(0, \sigma^2(g'(\vartheta))^2)$$

### Esempi

1. Considero

$$Y_n = \frac{\chi_n^2 - n}{\sqrt{2n}} = \sqrt{n} \left( \frac{\chi_n^2}{\sqrt{2n}} - \frac{1}{\sqrt{2}} \right)$$

ove  $\chi_n^2$  è la chiquadro con  $n$  gradi di libertà. Ricordiamo che  $\mathbb{E}(\chi_n^2) = n$  e che  $\text{Var}(\chi_n^2) = 2n$  (discende dal fatto che  $\chi_n^2 \sim \mathcal{G}(\alpha = n/2, \beta = 2)$ ). Siccome  $Y_n \xrightarrow{d} N(0, 1)$ , scrivendo  $Y_n$  nella forma  $Y_n = \sqrt{n} \left( \frac{\chi_n^2}{\sqrt{2n}} - \frac{1}{\sqrt{2}} \right)$  riconosciamo che la prima parte delle ipotesi del  $\Delta$ -method sono soddisfatte. Considero quindi  $g(t) = \sqrt{t}$ , che è derivabile in  $\vartheta = 1/\sqrt{2}$ ,  $g'(t) = \frac{1}{2\sqrt{t}}|_{\vartheta=1/\sqrt{2}} = 2^{-3/4}$ . Allora

$$\sqrt{n} \left( g \left( \frac{\chi_n^2}{\sqrt{2n}} \right) - g(\vartheta) \right) = \sqrt{n} \left( \sqrt{\frac{\chi_n^2}{\sqrt{2n}}} - \sqrt{\frac{1}{\sqrt{2}}} \right) \xrightarrow{d} N(0, 1^2 \cdot 2^{-3/2})$$

**Teorema 12.** (Teorema centrale del limite) Siano  $X_1, \dots, X_n$  vc iid dotate di media  $\mu$  e varianza finita  $\sigma^2$ . Allora

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n} \cdot \sigma} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1)$$

### Esempi/Applicazioni

1.  $X \sim b(n, p)$ ,  $X \stackrel{a}{\sim} N(np, np(1-p))$

2.  $X_1, \dots, X_n$  vc  $P(\lambda = 1)$ . Considero  $Y_n = \sum X_i$ . Dato che  $Y_n \stackrel{a}{\sim} N(n\lambda, n\lambda)$ ,  $\frac{Y_n}{n} \stackrel{a}{\sim} N(1, 1/n)$

3. Considerato  $W_n = \sqrt{n}(Y_n/n - 1) = \frac{Y_n/n - 1}{1/\sqrt{n}} = \frac{\bar{Y}_n - \mathbb{E}(\bar{Y}_n)}{\sqrt{\text{Var}(\bar{Y}_n/n)}}$

**Teorema 13.** Sia  $\{X_n\}$  una succ di vc iid con FGM  $M_{X_n}(t)$  definita e  $< \infty$  per  $t \in (-h, h) \forall n$ , e sia  $X$  un'altra vc con FGM  $M_X(t)$  definita e  $< \infty$  per  $t \in (-h_1, h_1)$ ,  $h_1 \leq h$ . Se

$$\lim_{n \rightarrow +\infty} M_{X_n}(t) = M_X(t) \forall |t| \leq h_1$$

allora  $X_n \xrightarrow{d} X$ .

### Applicazione

Sia  $X_n \sim b(n, p)$ . Ricordiamo che  $X_n = \sum X_i$  ove  $X_i \sim b(1, p)$ , ed inoltre  $\mu = \mathbb{E}(X) = np$ . Siccome  $M_{X_n}(t) = \mathbb{E}(e^{tX_n}) = [(1-p) + pe^t]^n = [1 + \frac{t}{n}(e^t - 1)]^n$ ,

$$M_{X_n}(t) \xrightarrow{n \rightarrow \infty} e^{\mu(e^t - 1)}$$

che è la FGM di una Poisson di parametro  $\mu$ .

## 2 Approccio alla Statistica Matematica

### 2.1 Introduzione

**Definizione 5.** (*Campione Casuale*) Il vettore casuale  $(X_1, \dots, X_n)$  si dice *Campione Casuale* relativamente ad una vc  $X \sim F_X(x, \vartheta)$  se i suoi elementi sono vc i.i.d.

**Osservazione** Il fatto che le vc siano i.i.d. implica che

$$F_{X_1, \dots, X_n}(X_1, \dots, X_n) = \prod_{i=1}^n F_{X_i}(X_i)$$

e

$$f_{X_1, \dots, X_n}(X_1, \dots, X_n) = \prod_{i=1}^n f_{X_i}(X_i)$$

**Definizione 6.** (*Statistica*) Sia  $(X_1, \dots, X_n)$  un campione casuale da una distribuzione associata alla vc  $X$ , e sia  $\Omega$  lo spazio campionario di  $(X_1, \dots, X_n)$

Ogni funzione

$$T(X_1, \dots, X_n) : \Omega \longrightarrow \mathbb{R}^k$$

che NON dipende da parametri incogniti è detta *Statistica*.

**Osservazioni** Le cose scritte tra virgolette " sono concetti e/o definizioni non ancora introdotti, che vengono usati per dare un'idea intuitiva di quello che si andrà a vedere, cose che poi durante il corso verranno trattate con rigore.

1. Una statistica  $T$  è una 'caratteristica numerica' del campione: si presta a *sintetizzare* l'informazione su  $\vartheta$  contenuta nel campione.
2.  $\sum_{i=1}^n X_i$  e  $\sum_{i=1}^n X_i^2$  sono entrambe statistiche: sono alla base di due 'stimatori' molto importanti:

$$\text{Media Campionaria: } \bar{X}_n = \frac{1}{n} \sum X_i$$

$$\text{Varianza Campionaria: } S_n^2 = \frac{1}{n-1} \sum (X_i - \bar{X}_n)^2 = \frac{1}{n-1} \sum X_i^2 - \frac{n}{n-1} \bar{X}_n^2$$

3. Ogni statistica è una vc: ha quindi una distribuzione, che dipende dal parametro.

**Esempio** Considero  $\bar{X} = \frac{1}{n} \sum X_i$  ove  $X_i \sim N(\mu, \sigma^2)$ . Allora  $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$ . Da questo si potrà dedurre la bontà di  $\bar{X}$  come stimatore di  $\mu$ .

4. Tra tutti i modi di sintetizzare l'informazione contenuta in  $(X_1, \dots, X_n)$  relativamente a  $\vartheta$ , siamo interessati a quelli che NON tralasciano informazioni o quote di informazioni rilevanti per il parametro.
5. In relazione ad uno stimatore potremmo essere interessati ad alcune proprietà, in particolare a queste due:
  - Accuratezza [concetto legato alla media dello stimatore] (*Non distorsione*)
  - Precisione [concetto legato alla varianza dello stimatore] (*efficienza o consistenza*)

## 2.2 Statistiche d'ordine

Lezioni 08 e 11 Marzo, ultima modifica 21/03, Scritte da: Marco Peruzzetto

**Definizione.** Sia  $(X_1, \dots, X_n)$  un campione casuale con distribuzione  $F_X(x, \theta)$ , densità  $f_X(x, \theta)$  e supporto  $\text{supp}\{X\} := (a, b) \subset \mathbb{R}$  ove  $X \in \{X_1, \dots, X_n\}$  e  $-\infty \leq a < b \leq +\infty$ . Definiamo ricorsivamente le seguenti variabili casuali:

- $X_{(1)} := \min(\{X_1, \dots, X_n\})$ ;
- $X_{(i)} := \min(\{X_1, \dots, X_n\} \setminus \{X_{(1)}, \dots, X_{(i-1)}\}) \quad \forall 1 < i \leq n$ .

Chiameremo allora  $X_{(i)}$  la  $i$ -esima *Statistica d'Ordine* del campione.

*Osservazione:* La statistica d'ordine consiste semplicemente nel vettore per il quale le variabili casuali vengono appunto ordinate, in base al valore che assumono in un determinato punto del loro dominio comune, in ordine crescente. In particolare  $X_{(i)}$  sarà l' $i$ -esima variabile più piccola. Naturalmente, se il campione ha lunghezza  $n$ , allora  $X_{(n)} = \max(\{X_1, \dots, X_n\})$ . Osserviamo che la funzione  $(X_1, \dots, X_n) \mapsto (X_{(1)}, \dots, X_{(n)})$  è essa stessa una Statistica.

**Teorema.** Sia  $(X_1, \dots, X_n)$  un campione casuale come sopra. Allora si ottiene  $\forall 1 \leq m \leq n$  che la densità dell' $m$ -esima statistica d'ordine è data da:

$$f_{X_{(m)}}(x, \theta) = \frac{n!}{(m-1)!(n-m)!} f_X(x, \theta) \cdot F_X(x, \theta)^{m-1} \cdot (1 - F_X(x, \theta))^{n-m}$$

Daremo due dimostrazioni, la seconda più bella della prima.

*Dimostrazione.* Innanzi tutto si ha che il supporto  $(a, b)$  può essere partizionato in  $n$  parti, per cui evidentemente si ha:

$$f_{(X_{(1)}, \dots, X_{(n)})}(x_{(1)}, \dots, x_{(n)}, \theta) = \begin{cases} n! \prod_{i=1}^n f_X(x_{(i)}, \theta) & \text{se } a < x_{(1)} < x_{(2)} < \dots < x_{(n)} < b \\ 0 & \text{altrimenti.} \end{cases}$$

ove la produttoria è giustificata dal fatto che le variabili sono tutte indipendenti e che devono essere ciascuna minore dell'altra per l'ordinamento assegnato; il coefficiente fattoriale è presente poiché le  $n$  parti dell'intervallo  $(a, b)$  possono essere assegnate alle  $n$  variabili in tale numero di modi, dato che ciascuna  $X_i \quad \forall 1 \leq i \leq n$  ha la stessa distribuzione.

Adesso per trovare la distribuzione di ciascuna  $X_{(m)}$  sarà dunque sufficiente integrare  $f_{(X_{(1)}, \dots, X_{(n)})}$  nei domini possibili di tutte le altre funzioni di distribuzione di ciascuna  $X_{(i)}$  con  $i \neq m$ . In particolare, ciascuna  $f_{X_{(i)}}$  per  $i < m$  dovrà assumere a piacere valori necessariamente inferiori a  $f_{X_{(m)}}$ , viceversa ogni  $f_{X_{(i)}}$  per  $i > m$  dovrà assumere valori obbligatoriamente superiori a quelli di  $f_{X_{(m)}}$  in ogni punto. Ricordando allora che possiamo scrivere la distribuzione come  $\int_a^x f_X(\theta, t) dt = F_X(\theta, x)$  essendo la densità la derivata della funzione di distribuzione, otterremo quindi che  $\forall a < x_{(m)} < b$  la distribuzione sarà data da:

$$\begin{aligned} f_{X_{(m)}}(x_{(m)}, \theta) &= \\ &= \int_a^{x_{(2)}} dx_{(1)} \cdots \int_a^{x_{(m)}} dx_{(m-1)} \int_{x_{(m)}}^b dx_{(m+1)} \cdots \int_{x_{(n-1)}}^b dx_{(n)} f_{(X_{(1)}, \dots, X_{(n)})}(x_{(1)}, \dots, x_{(n)}, \theta) \\ &= \int_a^{x_{(2)}} dx_{(1)} \cdots \int_a^{x_{(m)}} dx_{(m-1)} \int_{x_{(m)}}^b dx_{(m+1)} \cdots \int_{x_{(n-1)}}^b dx_{(n)} n! \prod_{i=1}^n f_X(x_{(i)}, \theta) \\ &= f_X(x_{(m)}) \int_a^{x_{(2)}} dx_{(1)} \cdots \int_a^{x_{(m)}} dx_{(m-1)} \int_{x_{(m)}}^b dx_{(m+1)} \cdots \int_{x_{(n-1)}}^b dx_{(n)} n! \prod_{i=1, i \neq m}^n f_X(x_{(i)}, \theta) \\ &= \frac{n!}{(m-1)!(n-m)!} f_X(x, \theta) \cdot F_X(x, \theta)^{m-1} \cdot (1 - F_X(x, \theta))^{n-m}, \end{aligned}$$

dove è stato usato il fatto che  $\int_a^b F_X^\alpha(\theta, t) f_X(\theta, t) dt = \frac{F_X^{\alpha+1}}{\alpha+1}$ ,  $\forall \alpha \neq -1$ . □



*Dimostrazione.* Sia  $\Omega$  il dominio comune del campione casuale. Definiamo per  $x \in \mathbb{R}$  la nuova variabile casuale  $Y_x$  come:

$$\Omega \longrightarrow \{0, \dots, n\}$$

$$Y_x(\omega) := \sum_{i=1}^n \mathbb{1}_{\{X_i(\omega) \leq x\}}(\omega) = \#\{i \in \{1, \dots, n\} : X_i \leq x\},$$

funzione che, per così dire, “conta” il numero di variabili casuali  $X_i$  che non superano  $x$ . Si vede immediatamente che  $\forall 1 \leq m \leq n$ , si ha la distribuzione

$$\begin{aligned} F_{X_{(m)}}(\theta, x) &= \mathbb{P}[Y_x \geq m] = \sum_{k=m}^n \mathbb{P}[Y_x = k] = \\ &= \sum_{k=m}^n \binom{n}{k} F_X^k(\theta, x) (1 - F_X(\theta, x))^{n-k}. \end{aligned}$$

Come nella prima dimostrazione usiamo il fatto che la densità si può vedere come derivata della funzione di ripartizione. Ne segue che per calcolare la densità sarà sufficiente calcolare la derivata in ciascun punto  $x$  della distribuzione appena trovata. In particolare si potrà vedere che coesisteranno il termine che vogliamo ottenere con altre due sommatorie, che tuttavia si elidono l'una con l'altra lasciando quindi la relazione espressa dal teorema. Si ha infatti che:

$$\begin{aligned} f_{(m)}(\theta, x) &= \frac{\partial}{\partial x} F_{X_{(m)}}(\theta, x) = \\ &= \sum_{k=m}^n \binom{n}{k} \cdot f_X(\theta, x) \left\{ k F_X^{k-1}(\theta, x) (1 - F_X(\theta, x))^{n-k} - (n-k) F_X^k(\theta, x) (1 - F_X(\theta, x))^{n-k-1} \right\} \\ &= m \binom{n}{m} \cdot f_X(\theta, x) F_X^{m-1}(\theta, x) (1 - F_X(\theta, x))^{n-m} + \\ &\quad \sum_{k=m+1}^n k \binom{n}{k} f_X(\theta, x) F_X^{k-1}(\theta, x) (1 - F_X(\theta, x))^{n-k} - \sum_{k=m}^n (n-k) \binom{n}{k} F_X^k(\theta, x) (1 - F_X(\theta, x))^{n-k-1} \\ &= \frac{n!}{(m-1)!(n-k)!} \cdot f_X(\theta, x) F_X^{m-1}(\theta, x) (1 - F_X(\theta, x))^{n-m} + \\ &\quad \sum_{j=m}^{n-1} (j+1) \binom{n}{j+1} f_X(\theta, x) F_X^j(\theta, x) (1 - F_X(\theta, x))^{n-j-1} - \sum_{k=m}^{n-1} (n-k) \binom{n}{k} F_X^k(\theta, x) (1 - F_X(\theta, x))^{n-k-1} \\ &= \frac{n!}{(m-1)!(n-k)!} \cdot f_X(\theta, x) F_X^{m-1}(\theta, x) (1 - F_X(\theta, x))^{n-m} + \\ &\quad \sum_{j=m}^{n-1} \frac{n!}{j!(n-j-1)!} f_X(\theta, x) F_X^j(\theta, x) (1 - F_X(\theta, x))^{n-j-1} - \sum_{k=m}^{n-1} \frac{n!}{k!(n-k-1)!} F_X^k(\theta, x) (1 - F_X(\theta, x))^{n-k-1} \\ &= \frac{n!}{(m-1)!(n-k)!} \cdot f_X(\theta, x) F_X^{m-1}(\theta, x) (1 - F_X(\theta, x))^{n-m}. \end{aligned}$$

□

**Definizione.** Sia  $(X_{(1)}, \dots, X_{(n)})$  una statistica d'ordine di un campione casuale. Allora possiamo definire le nuove seguenti variabili:

- $X_{(n)} - X_{(1)}$ , detta *Range* oppure *Misura di Dispersione*;
- $\frac{X_{(1)} + X_{(n)}}{2}$  detta *Mid Range* oppure *Misura di Centralità*;
- $\left. \begin{array}{l} \forall n \text{ pari} \quad \frac{X_{(\frac{n}{2})} + X_{(\frac{n}{2}+1)}}{2} \\ \forall n \text{ dispari} \quad X_{(\frac{n+1}{2})} \end{array} \right\}$  dette ciascuna *Mediana campionaria*;

- Sia  $\frac{1}{2(n+1)} < p < 1 - \frac{1}{2(n+1)}$ , che possiamo in ogni caso pensare come  $0 < p < 1$  per  $n$  molto grande. A questo punto possiamo definire l'intero  $k_p := \lfloor p(n+1) \rfloor + \lfloor 2(p(n+1) - \lfloor p(n+1) \rfloor) \rfloor$ , che risulta essere così ben definito in quanto compreso tra 1 e  $n$  e restituisce l'approssimazione all'intero più vicino al variare di  $p$  del reale  $p(n+1)$ .
- A questo punto, se scegliamo  $\xi_p \in F_X^{-1}(p)$ , chiameremo  $\xi_p$  *Quantile di popolazione* di ordine  $p$ . In seguito troveremo utile stimare tale valore. Perciò introduciamo la variabile casuale ad esso collegata  $X_{(k_p)}$ , detta *Quantile campionario* di ordine  $p$ . Se  $p = \frac{i}{m}$ , allora  $X_{(k_p)}$  è detta anche  $i$ -esimo  $m$ -ile campionario. In particolare con  $Q_1$  e  $Q_3$  si indicano rispettivamente il primo e il terzo quantile.
- Le variabili  $LF := Q_1 - h$  e  $UF := h + Q_3$ , ove  $h := \frac{3}{2}(Q_3 - Q_1)$  sono dette rispettivamente *Lower* e *Upper Fence*.

*Osservazione:* Osserviamo che più la misura di centralità si discosta dalla mediana, più vi è asimmetria nella funzione di distribuzione  $F$  (i.e.: una funzione di distribuzione è simmetrica  $:\Leftrightarrow \exists x_0 \in \mathbb{R} : F(x_0 + x) = F(x_0 - x), \forall x \in \text{Dom}(F)$ .) Inoltre, ponendo che la funzione di ripartizione sia iniettiva e simmetrica, si vede immediatamente che la media di popolazione, ovvero il quantile di popolazione di ordine  $p = \frac{1}{2}$  coincide con il valore di aspettazione della variabile casuale, il quale a sua volta deve coincidere con  $x_0$ .

Dato un campione casuale di parametro  $\theta \in \mathbb{R}$  fissato, sappiamo che una qualsiasi funzione di statistiche su tali variabili è, proprio per definizione, uno stimatore del parametro  $\theta$ . L'esistenza di un'infinità non numerabile di stimatori è sicuramente un problema da ovviare in merito alla scelta tra essi di uno stimatore che effettivamente permetta di stimare il più correttamente possibile il parametro  $\theta$ . Cercheremo dunque di individuare alcune proprietà che possano effettivamente giustificare la scelta di un determinato stimatore, affinché esso risulti il più possibile affidabile.

**Definizione.** Sia  $(X_1, \dots, X_n)$  un campione di parametro  $\theta$  e  $T_n(X_1, \dots, X_n)$  uno stimatore. La funzione  $B_\theta[T_n(X_1, \dots, X_n)] := \mathbb{E}_\theta[T_n(X_1, \dots, X_n)] - \theta$  si dice *distorsione* di  $T_n$ . In particolare  $T_n$  si dirà *non distorto* se e solo se la sua distorsione è nulla  $\forall \theta \in \mathbb{R}$ . Altrimenti si dice *distorto*. Se infine si ottiene che  $\lim_{n \rightarrow +\infty} B_\theta[T_n(X_1, \dots, X_n)] = 0$ ,  $T_n$  si dice *asintoticamente non distorto*.

*Esempio:* Sia  $(X_{(1)}, \dots, X_{(n)})$  un campione casuale con distribuzione simmetrica (senza perdita di generalità, la assumiamo simmetrica rispetto all'origine) e scegliamo come stimatore  $T_n$  proprio la mediana campionaria. È chiaro innanzi tutto che essa in generale gode delle seguenti due proprietà:

- $\forall b \in \mathbb{R}, T_n(X_1 + b, \dots, X_n + b) = T_n(X_1, \dots, X_n) + b;$
- $T_n(-X_1, \dots, -X_n) = -T_n(X_1, \dots, X_n).$

Abbiamo inoltre che la distribuzione di  $(X_1, \dots, X_n)$  e del vettore  $(X_1, \dots, X_n)$  coincidono (ricordando che l'origine è il centro di simmetria). Si avrà dunque:

$$\begin{aligned} \mathbb{E}[T_n] &= \mathbb{E}[T_n(X_1, \dots, X_n)] = \mathbb{E}[T_n(-X_1, \dots, -X_n)] \\ &= \mathbb{E}[T_n(-X_1, \dots, -X_n)] = \mathbb{E}[-T_n(X_1, \dots, X_n)] \\ &= -\mathbb{E}[T_n(X_1, \dots, X_n)] = -\mathbb{E}[T_n], \end{aligned}$$

perciò, in definitiva,  $2\mathbb{E}[T_n] = 0 \Leftrightarrow \mathbb{E}[T_n] = 0$ . Quindi, nel caso di una distribuzione simmetrica, la media campionaria è uno stimatore non distorto del valore di aspettazione, del

punto di simmetria e della media della popolazione (dato che tutti loro nel nostro caso coincidono).

*Esempio:* Sia  $(X_1, \dots, X_n)$  un campione casuale di parametro  $\theta \in \mathbb{R}$  fissato e con  $\mu := \mathbb{E}[X]$ ,  $\sigma^2 := \text{Var}[X]$ . Vogliamo provare a calcolare la distorsione di due stimatori “classici”:

1. Scegliamo come stimatore la *media campionaria*  $\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i$ . Allora  $B_\theta[\bar{X}_n] = \mathbb{E}_\theta[\bar{X}_n] - \theta = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_\theta[X_i] - \theta = \frac{1}{n} \cdot n \mathbb{E}_\theta[X] = \mu - \theta$ . Dunque la distorsione è costante  $\forall n \in \mathbb{N}$ . In particolare è uno stimatore non distorto per il valore di aspettazione  $\mu$ . Possiamo calcolare facilmente anche la varianza di  $\bar{X}_n$  che risulta essere  $\frac{\sigma^2}{n}$ . La media campionaria si rivela essere quindi un buon stimatore.
2. Prendiamo ora come stimatore la *varianza campionaria*, data dalla variabile  $S_n^2 := \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ . Allora:  

$$\mathbb{E}[S_n^2] = \frac{1}{n-1} \sum_{i=1}^n \mathbb{E}[(X_i - \bar{X}_n)^2] = \frac{1}{n-1} \sum_{i=1}^n \mathbb{E}[(X_i - \mu) - (\bar{X}_n - \mu)]^2 =$$

$$= \frac{1}{n-1} (\sum_{i=1}^n \mathbb{E}[(X_i - \mu)^2] - \sum_{i=1}^n \mathbb{E}[(\bar{X}_n - \mu)^2]) = \frac{1}{n-1} \cdot (n-1)\sigma^2 = \sigma^2.$$
Perciò  $S_n^2$  è uno stimatore non distorto di  $\sigma^2$ . Notiamo che lo stimatore  $S_n^* := \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$  avrebbe distorsione  $-\frac{\sigma^2}{n}$ , e dunque è peggiore della varianza campionaria, anche se è asintoticamente non distorto.

Calcoleremo adesso la varianza della varianza campionaria. Assumiamo per il momento che il campione provenga da una distribuzione normale  $N(\mu, \sigma^2)$ . In tal caso mostriamo che  $\frac{n-1}{\sigma^2} S_n^2 \sim \chi_{n-1}^2$  e dunque si avrà subito  $\text{Var}[S_n^2] = \frac{2\sigma^4}{n-1}$ . Infatti,  $\frac{n-1}{\sigma^2} S_n^2 = \sum_{i=1}^n \left( \frac{X_i - \bar{X}_n}{\sigma} \right)^2 = \sum_{i=1}^n \left( \frac{X_i - \mu}{\sigma} - \frac{\bar{X}_n - \mu}{\sigma} \right)^2 = \sum_{i=1}^n \left( \frac{X_i - \mu}{\sigma} \right)^2 - n \left( \frac{\bar{X}_n - \mu}{\sigma} \right)^2 = \sum_{i=1}^n \left( \frac{X_i - \mu}{\sigma} \right)^2 - \left( \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \right)^2 \Rightarrow \sum_{i=1}^n (\sim \chi_1^2) - (\sim \chi_1^2) \Rightarrow \frac{n-1}{\sigma^2} S_n^2 \sim \chi_{n-1}^2$ , ove abbiamo usato il seguente teorema:

**Teorema.** Sia  $(X_1, \dots, X_n)$  un campione casuale ove la funzione generatrice di ciascuna  $X_i$ ,  $1 \leq i \leq n$  è  $M_X(t)$ . Allora  $M_{\bar{X}_n}(t) = M_X(\frac{t}{n})^n$ .

per mostrare che  $\bar{X}_n \sim N(\mu, \frac{\sigma}{n})$ . Infatti:

$$M_{\bar{X}_n}(t) = M_X(\frac{t}{n})^n = \left( e^{\mu \frac{t}{n} + \frac{\sigma^2 t^2}{2n^2}} \right)^n = e^{\mu t + \frac{\sigma^2}{n} \cdot \frac{t^2}{2}}, \text{ da cui la tesi.}$$

**Teorema.** Sia  $(X_1, \dots, X_n)$  un campione casuale da una popolazione con distribuzione discreta o assolutamente continua dove la densità associata sia della forma  $f(x, \theta) = C(x)D(\theta) \exp\{\sum_{m=1}^k A_m(\theta)B_m(x)\}$  con  $k$  naturale positivo. Siano  $T_1, \dots, T_k$  statistiche definite  $\forall 1 \leq m \leq k$  da  $T_m(X_1, \dots, X_n) := \sum_{i=1}^n B_m(X_i)$ . Allora la distribuzione di  $(T_1, \dots, T_k)$  sarà ancora della forma esponenziale:

$$f_{(T_1, \dots, T_k)}(\theta, t_1, \dots, t_k) = C(t_1, \dots, t_k) D(\theta)^n \exp\left\{ \sum_{i=1}^k A_m(\theta) t_m \right\}$$

*Esempio.* Sia  $(X_1, \dots, X_n)$  un campione casuale. Supponiamo che  $X \sim \text{Bin}(1, p)$ . Allora la densità sarà discreta, ossia sarà  $f(p, x) = \mathbb{P}[X = x] = \mathbb{1}_{\{0,1\}}(x)(1-p) \exp\left\{ \log\left(\frac{p}{1-p}x\right) \right\}$ . Applicando il teorema otteniamo  $T_1(X_1, \dots, X_n) = \sum_{i=1}^n B_1(X_i) = \sum_{i=1}^n X_i$  da cui si deduce subito che  $T_1 \sim \text{Bin}(n, p)$ . In particolare possiamo scriverne la densità:  $f_{T_1}(p, t_1) = \mathbb{1}_{\{0, \dots, n\}}(t_1) \binom{n}{t_1} (1-p)^n \exp\left\{ \log\left(\frac{p}{1-p}t_1\right) \right\}$ .

*Esempio.* Sia  $(X_1, \dots, X_n)$  un campione casuale e supponiamo che il nostro campione casuale abbia distribuzione uniforme  $\text{Unif}([0, \theta])$ . Vogliamo stimare  $\theta$ . Supponiamo che, essendo  $\theta$  il massimo valore che ciascuna variabile può assumere, un plausibile buon stimatore possa essere proprio il massimo della statistica ordinata, ovvero  $T_n(X_1, \dots, X_n) := X_{(n)}$ . Ne conosciamo già la distribuzione:  $f_{T_n}(\theta, x) = \frac{n!}{(n-1)!(n-n)!} \frac{1}{\theta} \left(\frac{x}{\theta}\right)^{n-1} \left(1 - \frac{x}{\theta}\right)^{n-n} = \frac{n}{\theta^n} x^{n-1}$ . Allora  $\mathbb{E}[T_n] = \int_0^\theta \frac{n}{\theta^n} x^n dx = \frac{n}{n+1} \theta \neq \theta \implies B_\theta[T_n] = \frac{-1}{n+1}$ . Ne segue che è distorto, ma asintoticamente non distorto per  $\theta$ . Possiamo anche calcolarne la varianza:  $\text{Var}[T_n] = \mathbb{E}[T_n^2] - \mathbb{E}[T_n]^2 = \int_0^\theta \frac{n}{\theta^n} x^{n+1} dx - \frac{n}{n+1} \theta = \frac{n\theta^2}{(n+1)^2(n+2)} \xrightarrow{n \rightarrow \infty} 0$ . Perciò il massimo  $X_{(n)}$  rimane in ogni caso uno stimatore affidabile. Osserviamo che possiamo tuttavia introdurre un nuovo stimatore che ci assicura la non distorsione, ovvero  $T_n^* := \frac{n+1}{n} T$ , che possiede le proprietà cercate.

**Definizione.** Sia  $(X_1, \dots, X_n)$  un campione casuale con distribuzione  $F(\theta, x)$ , ove  $\theta \in \Theta \subset \mathbb{R}$ . Sia poi  $T_n$  una statistica  $\forall n \in \mathbb{N}$ . Diremo  $T_n$  essere uno stimatore *consistente* di  $\theta$  : $\iff T_n(X_1, \dots, X_n) \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \theta$ .

*Esempio.* Sia  $(X_1, \dots, X_n)$  un campione casuale, ove  $X \in \mathcal{L}^2(\mathbb{R})$ . Indichiamo come al solito media e varianza rispettivamente con  $\mu$  e  $\sigma^2$ . Allora abbiamo:

1. La media campionaria  $\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \mu$ , grazie alla legge debole dei grandi numeri poiché  $\lim_{n \rightarrow +\infty} \mathbb{P}[(\bar{X}_n - \mu) > \varepsilon] = 0, \forall \varepsilon > 0$ .
2. Consideriamo adesso la varianza campionaria

$$S_n^2 := \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{n}{n-1} \left( \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \right)$$

. Abbiamo ora i seguenti tre termini:

- $\lim_{n \rightarrow +\infty} \frac{n}{n-1} = 1$ , un semplice limite;
- $\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \mathbb{E}[X^2]$ , ancora grazie alla legge debole dei grandi numeri e al fatto che  $X^2$  rimane ancora sommabile;
- $\bar{X}_n^2 \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \mu^2 = \mathbb{E}[X]^2$  grazie al Teorema 4 sulla convergenza.

Ne segue quindi che  $S_n^2 \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \sigma^2$ , sempre per i teoremi sulla convergenza di somma, prodotto e prodotto per costanti di variabili casuali.

3. Consideriamo ancora il campione casuale distribuito uniformemente  $\text{Unif}([0, \theta])$  con stimatore  $T_n(X_1, \dots, X_n) := X_{(n)}$ . Troviamo che anch'esso è consistente per la stima del massimo. Infatti,  $\mathbb{P}[|T_n - \theta| > \varepsilon] = \mathbb{P}[\theta - T_n > \varepsilon] = \mathbb{P}[X_{(n)} \leq \theta - \varepsilon] = F_{X_{(n)}}(\theta - \varepsilon) = \left(1 - \frac{\varepsilon}{\theta}\right)^n \xrightarrow[n \rightarrow \infty]{} 0$ . Allo stesso modo si può verificare che anche  $T_n^*$  è consistente per  $\theta$ .

**Definizione.** Sia  $(X_1, \dots, X_n)$  un campione casuale e  $T_n : \mathfrak{X} \longrightarrow \mathcal{Y}_{T_n}$  una statistica (stimatore). Vi sia inoltre una funzione di parametri  $a : \Theta \longrightarrow \mathcal{Y}_\Theta$ . Allora la funzione non negativa  $\text{Loss} : (\mathcal{Y}_{T_n} \cup \mathcal{Y}_\Theta) \times \mathcal{Y}_\Theta \longrightarrow \mathbb{R}_{\geq 0}$  viene detta *Funzione di Perdita* se soddisfa alle seguenti condizioni:

1.  $\text{Loss}(a(\theta), a(\theta)) = 0, \forall \theta \in \Theta$ ;

2. Per ogni  $T_n \in \mathcal{T}$ , esiste una funzione  $\text{Risk} : Y_{T_n} \times Y_\Theta \rightarrow \mathbb{R}$ , detta *Funzione di Rischio*, tale che  $\text{Risk}(T_n, a(\theta)) = \mathbb{E}_\theta[\text{Loss}(T_n, a(\theta))]$ ,  $\forall \theta \in \Theta$ .

*Osservazione.* La funzione di perdita può essere pensata come una misura della discrepanza tra l'azione  $T_n$  e lo stato della natura  $a(\theta)$ .

**Definizione.** Possiamo già definire due tipologie di funzioni di perdita che spesso vengono utilizzate in statistica:

1.  $\text{Loss}_1(T_n, a(\theta)) := |T_n - a(\theta)|$ , chiamata *Errore assoluto*;
2.  $\text{Loss}_2(T_n, a(\theta)) := (T_n - a(\theta))^2$ . Essa ammette anche come possibile funzione di rischio  $\text{Risk}_2(T_n, a(\theta)) := \mathbb{E}_\theta[T_n - a(\theta)]^2$ ; se tuttavia  $a = \text{id}_\Theta$ , allora la funzione  $\text{MSE}_\theta(T_n) := \text{Risk}_2(T_n, \theta)$  prende il nome di *Mean Square Error* (oppure *Errore Quadratico Medio*).

*Osservazione.* Semplicemente aggiungendo e sottraendo il valore  $\mathbb{E}[T_n]$  si ottiene subito la seguente uguaglianza:  $\text{MSE}_\theta(T_n) = \text{Var}_\theta[T_n] + B_\theta[T_n]^2$ .

**Teorema.** Sia  $T_n$  uno stimatore di  $\theta$  (non necessariamente non distorto). Allora si ha che  $\lim_{n \rightarrow +\infty} \text{MSE}_\theta(T_n) = 0$  è condizione sufficiente (ma non necessaria) per la consistenza di  $T_n$ .

*Dimostrazione.* Si ha infatti la seguente semplice catena di disuguaglianze:

$$\begin{aligned} \mathbb{P}[|T_n - \theta| > \varepsilon] &= \int_{|T_n - \theta| > \varepsilon} f_{T_n}(\theta, t_n) dt_n \\ &< \int_{|T_n - \theta| > \varepsilon} \frac{(t_n - \theta)^2}{\varepsilon^2} f_{T_n}(\theta, t_n) dt_n < \frac{1}{\varepsilon^2} \text{MSE}_\theta(T_n). \end{aligned}$$

□

## 2.3 Intervalli di confidenza

Lezione del 15/03, ultima modifica 26/03, Michele Nardin

**Definizione 7.** Sia  $(X_1, \dots, X_n)$  un campione casuale da una distribuzione con funzione di ripartizione  $F_X(x, \vartheta)$ ,  $\vartheta \in \Theta$ . Definiamo Statistica Pivot una funzione  $Q((X_1, \dots, X_n), \vartheta)$  tale che

1.  $Q$  è funzione del campione casuale e del parametro  $\vartheta$  (parametro su cui si vuol fare inferenza)
2.  $Q$  non contiene parametri incogniti oltre a  $\vartheta$
3. la distribuzione di  $Q$ ,  $F_Q$ , è completamente nota (ossia non dipende da  $\vartheta$ )
4.  $Q$  è invertibile rispetto a  $\vartheta$

**Esempi:** Campione casuale da  $N(\mu, \sigma^2)$ :

1. Supponiamo di conoscere la varianza: allora un esempio di statistica pivot è

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$$

la quale, grazie all'ipotesi di campionamento da vc normale, ha distribuzione  $N(0,1)$ .

2. Supponiamo di non conoscere la varianza: in tal caso, al posto della varianza usiamo lo stimatore varianza campionaria  $S_n^2$ , il quale è non distorto (già dimostrato) e consistente (infatti  $MSE_{\sigma^2}(S_n^2) = Var(S_n^2) + B^2(S_n^2) = \frac{2\sigma^4}{n-1} \rightarrow 0$ ) e quindi la statistica pivot in questione sarà

$$Q = \frac{\bar{X}_n - \mu}{S_n / \sqrt{n}}$$

la quale (dimosteremo che) ha distribuzione t-student con n-1 gradi di libertà.

Siano  $(X_1, \dots, X_n)$  da una vc avente cdf  $F_X(x, \vartheta)$ . Vogliamo stimare  $\vartheta$ : per farlo usiamo uno stimatore  $T_n$ . Quando il campione casuale sarà effettivamente estratto, avremo una n-upla di valori reali  $(x_1, \dots, x_n)$ , i quali permettono di calcolare l'effettivo valore della stima: è impensabile però che la stima coincida esattamente con il valore (se X ha distribuzione continua  $\mathbb{P}(T_n = \vartheta) = 0!$ ). Dobbiamo quindi associare a  $T_n$  un margine di errore.

**Esempio introduttivo (exit poll)** Vogliamo stimare la proporzione  $p_i$  dei voti ricevuti dall'iesimo partito sul totale. Il nostro problema sarà quello di trovare un intervallo centrato nella stima  $\hat{p}_i$ , ed un margine d'errore,  $ME$ , tale per cui, ad un fissata soglia di probabilità  $\alpha$  si abbia

$$P(p_i \in (\hat{p}_i - ME, \hat{p}_i + ME)) = 1 - \alpha$$

### 2.3.1 Costruzione generale

In generale, sia  $\vartheta_0$  il valore vero del parametro  $\vartheta$  che vogliamo stimare, e per semplicità assumiamo che  $T_n$  sia un suo stimatore tale che

$$\sqrt{n}(T_n - \vartheta_0) \xrightarrow{d} N(0, \sigma_{T_n}^2)$$

Per il momento assumiamo di conoscere  $\sigma_{T_n}^2$ , sicché

$$Z_n = \frac{\sqrt{n}(T_n - \vartheta_0)}{\sigma_{T_n}} \stackrel{a}{\sim} N(0, 1)$$

Bisogna notare che  $Z_n$  è una statistica pivot. Fissato  $\alpha \in (0, 1)$ , consideriamo i quantili della distribuzione  $N(0, 1)$ ,  $\pm z_{\alpha/2}$  (ossia quei valori tali per cui, se  $X \sim N(0, 1)$ ,  $P(-z_{\alpha/2} \leq X \leq z_{\alpha/2}) = 1 - \alpha$ ). Possiamo affermare che, per n sufficientemente grande, (il simbolo  $\doteq$  indica un'uguaglianza approssimata)

$$P(-z_{\alpha/2} \leq Z_n \leq z_{\alpha/2}) \doteq 1 - \alpha$$

da cui

$$P(-z_{\alpha/2} \leq \frac{\sqrt{n}(T_n - \vartheta_0)}{\sigma_{T_n}} \leq z_{\alpha/2}) \doteq 1 - \alpha$$

e ancora

$$P(T_n - z_{\alpha/2} \frac{\sigma_{T_n}}{\sqrt{n}} \leq \vartheta_0 \leq T_n + z_{\alpha/2} \frac{\sigma_{T_n}}{\sqrt{n}}) \doteq 1 - \alpha$$

Possiamo quindi definire un intervallo casuale,

$$IC = \left[ T_n - z_{\alpha/2} \frac{\sigma_{T_n}}{\sqrt{n}}, T_n + z_{\alpha/2} \frac{\sigma_{T_n}}{\sqrt{n}} \right]$$

(è casuale perchè per  $T_n$  è una vc).  $IC$  è uno Stimatore Intervallare. Si può affermare che  $P(\vartheta \in IC) \doteq 1 - \alpha$ .

**Nomenclatura** :  $z_{\alpha/2}$  si dice Fattore di Affidabilità,  $\frac{\sigma_{T_n}}{\sqrt{n}}$  si dice Standard Error dello stimatore  $T_n$ .

Sia ora  $(x_1, \dots, x_n)$  una determinazione campionaria (ossia i dati effettivamente osservati da un campione casuale) (cioè una n-upla) e sia  $T_n(x_1, \dots, x_n) = t_n$  l'effettivo valore assunto dallo stimatore. Definiamo **l'intervallo di confidenza con probabilità di copertura**  $1 - \alpha$

$$IC_{\vartheta}(1 - \alpha) := \left[ t_n - z_{\alpha/2} \frac{\sigma_{T_n}}{\sqrt{n}}, t_n + z_{\alpha/2} \frac{\sigma_{T_n}}{\sqrt{n}} \right]$$

La probabilità di copertura viene anche detta livello di confidenza.

Nella pratica,  $\sigma_{T_n}^2$  non è noto a priori. Possiamo però usare lo stimatore varianza campionaria di  $T_n$ ,  $S_{T_n}^2$ , il quale sappiamo che converge in probabilità a  $\sigma_{T_n}^2$ . Allora, per il teorema di Slutsky, troviamo che

$$Z_n = \frac{\sqrt{n}(T_n - \vartheta_0)}{S_{T_n}} = \frac{\sqrt{n}}{S_{T_n}} T_n - \frac{\sqrt{n}}{S_{T_n}} \vartheta_0 \xrightarrow{d} N(0, 1)$$

Possiamo quindi ripetere il ragionamento fatto poco sopra usando la varianza campionaria al posto di  $S_{T_n}^2$ , e quindi costruire l'intervallo di confidenza con probabilità di copertura pari a  $1 - \alpha$  come

$$IC_{\vartheta}(1 - \alpha) := \left[ t_n - z_{\alpha/2} \frac{S_{T_n}}{\sqrt{n}}, t_n + z_{\alpha/2} \frac{S_{T_n}}{\sqrt{n}} \right]$$

### 2.3.2 Intervallo di confidenza per la media $\mu$

Sia  $(X_1, \dots, X_n)$  un campione casuale, media e varianza incognite. Siano  $\bar{X}_n$  e  $S_n^2$  gli stimatori di media e varianza della popolazione. Allora per il TLC e per il teorema di Slutsky si ha che

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{S_n} \xrightarrow{d} N(0, 1)$$

che è una statistica pivot. Quindi l'intervallo di confidenza con probabilità di copertura  $1 - \alpha$  (sempre approssimato) sarà

$$IC_{\mu}(1 - \alpha) = \left[ \bar{X}_n - z_{\alpha/2} \frac{S_n}{\sqrt{n}}, \bar{X}_n + z_{\alpha/2} \frac{S_n}{\sqrt{n}} \right]$$

### 2.3.3 Intervallo di confidenza per una proporzione $p$

Sia  $(X_1, \dots, X_n)$  un campione casuale da  $b(1, p)$  e sia  $\hat{p}_n = \frac{1}{n} \sum_{i=1}^n X_i$  lo stimatore (corretto e consistente) di  $p$ . Troviamo che per il TLC e per la WLLN

$$\frac{\sqrt{n}(\hat{p}_n - p)}{\sqrt{\hat{p}_n(1 - \hat{p}_n)}} \xrightarrow{d} N(0, 1)$$

e quindi l'intervallo di confidenza con probabilità di copertura  $1 - \alpha$  approssimato sarà

$$IC_p(1 - \alpha) = \left[ \hat{p}_n - z_{\alpha/2} \sqrt{\frac{\hat{p}_n(1 - \hat{p}_n)}{n}}, \hat{p}_n + z_{\alpha/2} \sqrt{\frac{\hat{p}_n(1 - \hat{p}_n)}{n}} \frac{S_n}{\sqrt{n}} \right]$$

### 2.3.4 Distribuzione esatta della statistica pivot: distribuzione t di Student

Lezione del 18/03, ultima modifica 26/03, Michele Nardin

La distribuzione di Student con  $\nu$  gradi di libertà è definita come  $T = \frac{Z}{\sqrt{S^2/\nu}}$  ove  $Z \sim N(0, 1)$  mentre  $S^2 \sim \chi_\nu^2$  (chiquadro con  $\nu$  gradi di libertà). La funzione di densità è

$$f_{t_\nu}(t, \nu) = \frac{\Gamma((\nu+1)/2)}{\Gamma(\nu/2)} \frac{1}{\sqrt{\pi\nu}} \frac{1}{[1+t^2/\nu]^{\frac{\nu+1}{2}}} \mathbb{1}_{\mathbb{R}}(t)$$

tale funzione è simmetrica, ha la classica forma a campana come la normale, ma a differenza di quest'ultima ha le code più pesanti. Risulta che la statistica pivot per la media in campioni poco numerosi <sup>1</sup> (in caso di campionamento da normale) ha distribuzione esatta t di Student. Infatti

$$Q = \frac{\bar{X}_n - \mu}{S_n/\sqrt{n}} = \frac{\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}}{\sqrt{\frac{S_n^2}{\sigma^2}}}$$

troviamo al numeratore  $\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ , (grazie al fatto che le  $X_i$  sono equi distribuite normalmente) mentre al denominatore abbiamo che

$$\sqrt{\frac{S_n^2}{\sigma^2}} = \sqrt{\frac{(n-1)S_n^2}{(n-1)\sigma^2}} = \sqrt{\frac{H}{(n-1)}}$$

Abbiamo già dimostrato che  $H = \frac{(n-1)S_n^2}{\sigma^2} \sim \chi_{n-1}^2$ , quindi al denominatore abbiamo la radice di una chiquadro diviso i suoi gradi di libertà.

Quindi, quando il campione casuale è poco numeroso, è conveniente usare i quantili della distribuzione t di student per costruire gli intervalli di confidenza. Per numerosità campionarie  $n > 30$ , approssimare la distribuzione t di student con la distribuzione normale offre risultati soddisfacenti. Ricordiamo che per il tlc  $Q \rightarrow N(0, 1)$

Fissato un livello di confidenza  $1 - \alpha$ , consideriamo i quantili della distribuzione t di student (con n-1 gradi di libertà, ove n è la dimensione campionaria)  $\pm t_{(\alpha/2; n-1)}$ , troviamo

$$P\left(-t_{(\alpha/2; n-1)} \leq \frac{\bar{X}_n - \mu}{S_n/\sqrt{n}} \leq t_{(\alpha/2; n-1)}\right) = 1 - \alpha$$

Notiamo che questa volta vale l'uguaglianza 'vera', poiché non stiamo considerando approssimazioni asintotiche. In presenza del campione effettivamente estratto,  $(x_1, \dots, x_n)$ , scriviamo  $\bar{x}_n$  e  $s_n^2$  i valori assunti da media e varianza campionaria, l'intervallo di confidenza è

$$IC_\mu(1 - \alpha) = \left[ \bar{x}_n - t_{(\alpha/2; n-1)} \sqrt{\frac{s_n^2}{n}}, \bar{x}_n + t_{(\alpha/2; n-1)} \sqrt{\frac{s_n^2}{n}} \right]$$

**Osservazione 5.** Alcune osservazioni che, pur sembrando banali, è bene tenere a mente:

1. Al crescere del livello di confidenza  $(1 - \alpha)$  e/o della varianza campionaria  $S_n^2$  cresce anche l'ampiezza di IC
2. Al crescere dell'ampiezza campionaria  $n$ , (fermo restando il livello di confidenza) l'ampiezza di IC diminuisce

---

<sup>1</sup>In realtà vale per tutti i campioni, è solo che da un certo punto in poi la differenza con la normale è davvero trascurabile! Sulle tavole si riporta solo per  $\nu < 120$



### 2.3.5 Intervalli di confidenza per la varianza

Sia  $(X_1, \dots, X_n)$  un campione casuale da  $N(\mu, \sigma^2)$ . Consideriamo la statistica pivot

$$W = \frac{n-1}{\sigma^2} S_n^2$$

Abbiamo già mostrato che  $W \sim \chi_{n-1}^2$ . Ma allora, dato che noi cerchiamo  $q_1, q_2$  te

$$P(q_1 \leq \frac{n-1}{\sigma^2} S_n^2 \leq q_2) = 1 - \alpha$$

troviamo che essi sono i quantili di ordine  $\alpha/2$  e  $1 - \alpha/2$  della chiquadro con  $n-1$  gradi di libertà, che indicheremo  $q_1 = \chi_{(n-1, \alpha/2)}^2$  e  $q_2 = \chi_{(n-1, 1-\alpha/2)}^2$ . Con qualche passaggio otteniamo:

$$P\left(\frac{1}{q_2} \leq \frac{\sigma^2}{(n-1)S_n^2} \leq \frac{1}{q_1}\right) = 1 - \alpha$$
$$P\left(\frac{(n-1)S_n^2}{q_2} \leq \sigma^2 \leq \frac{(n-1)S_n^2}{q_1}\right) = 1 - \alpha$$

Troviamo così l'intervallo casuale (e di conseguenza il relativo intervallo di confidenza, una volta estratto il campione e trovato un valore a  $S_n^2$ )

$$IC = \left[ \frac{(n-1)S_n^2}{q_2}, \frac{(n-1)S_n^2}{q_1} \right]$$

### 2.3.6 Intervalli di confidenza per la differenza di medie

Vogliamo confrontare due distribuzioni: *sintetizziamo* la differenza tra due popolazioni tramite la differenza delle loro media.

Supponiamo inizialmente di avere due campioni casuali tra loro indipendenti:

$(X_1, \dots, X_{n_1})$  da una distribuzione D1, con media  $\mu_1$  (ignota) e varianza  $\sigma_1^2$  (nota)

$(Y_1, \dots, Y_{n_2})$  da una distribuzione D2, con media  $\mu_2$  (ignota) e varianza  $\sigma_2^2$  (nota)

NB: non necessariamente  $n_1$  dev'essere uguale a  $n_2$

Consideriamo gli stimatori media campionaria per le due medie, che indicheremo con  $\bar{X}$  e  $\bar{Y}$ . La statistica pivot che ci interessa per  $\Delta = \mu_1 - \mu_2$  sarà

$$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\left[ \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2} \right]^{\frac{1}{2}}}$$

Notiamo che  $var(\bar{X} - \bar{Y}) = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}$  dato che  $cov(\bar{X}, \bar{Y}) = 0$  per l'indipendenza. Ma allora  $Z \stackrel{a}{\sim} N(0, 1)$ , quindi possiamo trovare un intervallo di confidenza <sup>2</sup>

$$IC_{\Delta}(1 - \alpha) = [(\bar{X} - \bar{Y}) - ME; (\bar{X} - \bar{Y}) + ME]$$

ove  $ME = z_{\alpha/2} \left[ \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2} \right]^{\frac{1}{2}}$ . Al posto delle varianze possiamo usare anche gli stimatori corretti e consistenti varianza campionaria, e giungere allo stesso risultato per il teorema di Slutsky.

---

<sup>2</sup>Approssimato, visto che conosciamo solo l'andamento asintotico di Z! D1 e D2 non è detto che siano normali!

In generale non conosciamo la varianza delle distribuzioni: in base al problema che dobbiamo affrontare, può essere plausibile supporre di conoscere la distribuzione delle due popolazioni a meno di uno o più parametri.

**Location Model:** Supponiamo di avere  $(X_1, \dots, X_{n_1})$  da distribuzione normale con media  $\mu_1$  e varianza  $\sigma_1^2$  (ignote), i loro stimatori  $\bar{X}$  e  $S_1^2$  e  $(Y_1, \dots, Y_{n_2})$  da distribuzione normale con media  $\mu_2$  e varianza  $\sigma_2^2$  (ignote) e i loro stimatori  $\bar{Y}$  e  $S_2^2$ . Supponiamo che i due campioni siano tra loro indipendenti ed inoltre che  $\sigma_1 = \sigma_2 = \sigma$ . Possiamo 'fondere' le informazioni contenute in  $S_1^2$  e  $S_2^2$ :

$$(PooledVariance) S_p^2 := \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

che risulta essere uno stimatore corretto e consistente di  $\sigma^2$  (esercizio). La statistica Pivot che prendiamo in considerazione sarà

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_p \left( \frac{1}{n_1} + \frac{1}{n_2} \right)^{\frac{1}{2}}}$$

la quale risulta essere distribuita come  $t_{n_1+n_2-2}$ . Ricalcando i passaggi delle applicazioni precedenti, fissato  $\alpha$  troviamo l'intervallo casuale per  $\Delta$

$$IC = \left[ (\bar{X} - \bar{Y}) - t_{(n_1+n_2-2; \alpha/2)} S_p \left( \frac{1}{n_1} + \frac{1}{n_2} \right)^{\frac{1}{2}} ; (\bar{X} - \bar{Y}) + t_{(n_1+n_2-2; \alpha/2)} S_p \left( \frac{1}{n_1} + \frac{1}{n_2} \right)^{\frac{1}{2}} \right]$$

### 2.3.7 Intervalli di confidenza per la differenza di proporzioni

Supponiamo di avere  $(X_1, \dots, X_{n_1})$  da distribuzione  $b(1, p_1)$ , con stimatore  $\hat{p}_1$  e  $(Y_1, \dots, Y_{n_2})$  da distribuzione  $b(1, p_2)$ , con stimatore  $\hat{p}_2$ . Supponiamo che i due campioni siano tra loro indipendenti. Allora

$$\Delta = \hat{p}_1 - \hat{p}_2 \stackrel{a}{\sim} N \left( p_1 - p_2, \frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2} \right)$$

quindi usando la statistica Pivot

$$Z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\left( p_1 - p_2, \frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2} \right)}} \stackrel{a}{\sim} N(0, 1)$$

trovo l'intervallo di confidenza

$$IC_{\Delta}(1 - \alpha) = \left[ (\hat{p}_1 - \hat{p}_2) - z_{\alpha/2} \sqrt{A(p_1, p_2)} ; (\hat{p}_1 - \hat{p}_2) + z_{\alpha/2} \sqrt{A(p_1, p_2)} \right]$$

ove  $A(p_1, p_2) = \left( \frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2} \right)$ . Ovviamente al posto di  $p_1$  e  $p_2$  uso gli stimatori corretti e consistenti  $\hat{p}_1$  e  $\hat{p}_2$ .

Lezione del 20 marzo, ultima modifica 26 marzo, Michele Nardin

### 2.3.8 Intervalli di confidenza per rapporti di varianze

#### Distribuzione F di Snedecor-Fisher

Siano  $W_1 \sim \chi_{\nu_1}^2$  e  $W_2 \sim \chi_{\nu_2}^2$  indipendenti. La distribuzione  $F_{\nu_1, \nu_2}$  è definita come il rapporto tra due chiquadrato divise per i rispettivi gradi di libertà, in formule

$$W = \frac{W_1/\nu_1}{W_2/\nu_2}$$

ed ha funzione di densità

$$f_W(w; \nu_1, \nu_2) = \frac{\Gamma(\frac{\nu_1 + \nu_2}{2})}{\Gamma(\frac{\nu_1}{2}) + \Gamma(\frac{\nu_2}{2})} (\nu_1/\nu_2)^{\nu_1/2} w^{\nu_1/2-1} \left[1 - \frac{\nu_1}{\nu_2} w\right]^{\frac{\nu_1 + \nu_2}{2}} \mathbb{1}_{\mathbb{R}^+}(w)$$

Vale la seguente proprietà, utile per calcolare i quantili non tabulati:

$$Se W \sim F_{\nu_1, \nu_2} \Rightarrow \frac{1}{W} \sim F_{\nu_2, \nu_1}$$

Le tavole (comunemente) forniscono i valori dei quantili per  $(1-\alpha) \in 0.80, 0.90, 0.95, 0.975, 0.99, 0.999$ . Quindi possiamo sfruttare la proprietà sopra scritta per trovare che

$$w_{\alpha; \nu_1, \nu_2} = \frac{1}{w_{1-\alpha; \nu_1, \nu_2}}$$

#### Intervallo di confidenza per rapporti di varianze

Supponiamo di avere  $(X_1, \dots, X_{n_1})$  da distribuzione normale con media  $\mu_1$  e varianza  $\sigma_1^2$  (ignote), i loro stimatori  $\bar{X}$  e  $S_1^2$  e  $(Y_1, \dots, Y_{n_2})$  da distribuzione normale con media  $\mu_2$  e varianza  $\sigma_2^2$  (ignote) e i loro stimatori  $\bar{Y}$  e  $S_2^2$ . Ricordiamo che  $\frac{(n_1-1)S_1^2}{\sigma_1^2} \sim \chi_{n_1-1}^2$  (idem per  $S_2^2$ ).

Fissato  $1 - \alpha$  consideriamo una statistica pivot e  $w_1, w_2$  tc  $P(w_1 \leq W \leq w_2) = 1 - \alpha$ . La statistica pivot in questione sarà

$$W = \frac{\frac{(n_1-1)S_1^2}{\sigma_1^2}/n_1 - 1}{\frac{(n_2-1)S_2^2}{\sigma_2^2}/n_2 - 1} \sim F_{(n_1-1), (n_2-1)}$$

poichè rapporto di due chiquadro. Risulta inoltre, semplificando:

$$W = \frac{S_1^2}{\sigma_1^2} \frac{S_2^2}{\sigma_2^2} = \frac{\sigma_2^2}{\sigma_1^2} \frac{S_1^2}{S_2^2}$$

$w_1$  e  $w_2$  saranno i quantili di ordine  $\alpha/2$  e  $1 - \alpha/2$  della distribuzione  $F_{(n_1-1), (n_2-1)}$ , esplicitamente  $w_1 = w_{(n_1-1, n_2-1; \alpha/2)} = \frac{1}{w_{(n_2-1, n_1-1; 1-\alpha/2)}}$  e  $w_2 = w_{(n_1-1, n_2-1; 1-\alpha/2)}$  e quindi troviamo che

$$1 - \alpha = P(w_1 \leq \frac{\sigma_2^2}{\sigma_1^2} \frac{S_1^2}{S_2^2} \leq w_2) = P\left(\frac{S_1^2/S_2^2}{w_2} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2/S_2^2}{w_1}\right)$$

da cui troviamo anche il relativo intervallo casuale. Quando invece abbiamo un campione effettivamente estratto, posti  $s_1^2$  e  $s_2^2$  i valori assunti dalla varianza campionaria, l'intervallo di confidenza sarà

$$IC_{\frac{\sigma_1^2}{\sigma_2^2}}(1 - \alpha) = \left[\frac{s_1^2/s_2^2}{w_2}, \frac{s_1^2/s_2^2}{w_1}\right] = \left[\frac{s_1^2/s_2^2}{w_{(n_1-1, n_2-1; 1-\alpha/2)}}, \frac{s_1^2/s_2^2}{\frac{1}{w_{(n_2-1, n_1-1; 1-\alpha/2)}}}\right]$$